



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ESCUELA DE INGENIERÍA

Departamento de Ingeniería Química y Bioprocesos (DIQB)

www.ing.puc.cl/iiq

IIQ3402 Diseño estadístico, Optimización y Análisis Multivariado

Tarea 2

Fecha de entrega: jueves 12 de junio vía Canvas hasta las 23h59

Modalidad: En parejas o individual. Los estudiantes escogen libremente con cómo y con quién trabajar.

I. Descripción

El propósito de esta tarea es evaluar las competencias asociadas a las Unidades 3 y 4 del curso en un caso de estudio real. Esta tarea está diseñada para que los estudiantes exploren, formulen y respondan preguntas de investigación a partir de los métodos revisados hasta ahora.

En esta tarea se analizarán datos y resultados de investigaciones científicas a partir de los cuales deberán aplicar conceptos y tests estadísticos pertinentes que permitan extraer conclusiones relevantes. Todos los resultados encontrados en la tarea deberán ser respaldados con los cálculos respectivos.

II. Instrucciones

La tarea consta de tres (3) problemas. Cada una de ellas aborda el análisis de datos extraídos de literatura científica o técnica. Para la realización de la tarea se deben analizar los datos disponibles indicados en la siguiente sección.

Problema 1 (20 pts.) Un estudio está interesado en desarrollar un tratamiento efectivo contra los herpes labiales. Recientemente se desarrollaron 4 potenciales tratamientos (t1, t2, t3 y t4). Para evaluar la efectividad de cada tratamiento, se asignaron de forma aleatoria 30 pacientes con brotes labiales, agrupados en 6 muestras (m1, m2, m3, m4, m5 y m6) de 5 pacientes, a los 4 tratamientos más un grupo placebo (control). En cada caso se registró el número de días desde el brote del herpes hasta su completa recuperación. Los resultados del estudio están disponibles en el archivo `herpes.xls`. A partir de esta información:

- a) Realice un análisis preliminar de los datos, incluyendo discusión, y descripción de las variables. ¿Existe algún tratamiento que destaque por sobre otro? ¿Por qué?
- b) Reporte la estadística descriptiva (promedio y desviación estándar) y construya un intervalo de confianza al 95% para cada tratamiento. Complemente lo concluido en 1a) a la luz de sus resultados.
- c) Compruebe la respuesta anterior mediante una prueba de hipótesis utilizando un nivel de significancia $\alpha = 0.05$. Siga los lineamientos de prueba de hipótesis mencionada en clases.
- d) En el caso que existan diferencias significativas, ¿Cuál(es) de los niveles son estadísticamente diferentes entre sí? En el caso que no haya diferencias, discuta brevemente porqué pudo no haberse observado diferencias.
- e) ¿Cuál recomendación daría Ud. como asesor experto para continuar este estudio? Comente a partir de los resultados obtenidos.

Problema 2 (10 ptos.) Se analizó el efecto del ácido linoleico en la dieta de 17 individuos por 4 semanas como parte de un estudio de enfermedades cardiovasculares. Se midió la presión sanguínea (sistólica) antes de las 4 semanas (línea base), y luego transcurridas 4 semanas. Los resultados del estudio se reportan en el archivo `presion.xls`. A partir de esta información, responda:

- a) ¿Qué test paramétrico se puede usar para evaluar el efecto de ácido linoleico en la presión sanguínea? Justifique su elección.
- b) Realice el test escogido en 2a) y reporte el valor-p crítico y el intervalo de confianza del 95% para la presión sanguínea media bajo este test. ¿Qué se puede concluir?
- c) ¿Qué test no paramétrico se podría usar en este caso? Explique. Además, realice este test y determine el valor-p crítico y el intervalo de confianza del 95%. ¿Qué se puede concluir?
- d) Discuta los resultados obtenidos con ambos tests. ¿Qué test es más apropiado? Explique.

Problema 3 (30 ptos.) Los datos presentados en el archivo `jet.xls` presentan el impulso de un motor de turbina de jet (y) y cinco variables explicativas potenciales: la rotación primaria de velocidad (x_1), la velocidad secundaria de rotación (x_2), la tasa de flujo de combustible (x_3), la presión del sistema (x_4), y la temperatura de escape (x_5). A partir de esta información:

- a) Construya un modelo nulo del impulso del motor (y). Reporte la ecuación del modelo y explique brevemente ¿Por qué es necesario un modelo nulo?
- b) Realice un análisis exploratorio de los datos. Evalúe la asociación de cada variable explicativa con la variable respuesta (y). ¿Qué variables podrían presentar una asociación con el impulso de un motor de turbina de jet (y)? ¿Cuáles no? Se espera que en este punto reporten resúmenes estadísticos para cada comparación junto con el coeficiente de correlación de Pearson.
- c) Construya un modelo de regresión lineal con todas las variables para un nivel de significancia $\alpha = 0.01$. ¿Coincide con lo observado en 3b)? Se espera que reporten la estadística y el desempeño del modelo de regresión.
- d) ¿Es posible mejorar el modelo? Si es así, haga una selección de variables. Reporte nuevamente la estadística y desempeño del modelo mejorado.

- e) Compare el modelo de 3d) con el nulo. ¿Es este modelo superior al modelo nulo? Explique.
- f) Verifique si se cumplen las condiciones de regresión. En base a su análisis, ¿Qué tan confiados se puede estar con los resultados del modelo? Comente brevemente.
- g) Realice una transformación logarítmica ($\log_{10}$) de la variable respuesta y las variables explicativas salvo x_5 (elimine esta variable). Construya nuevamente un modelo de regresión y reporte la estadística y desempeño del nuevo modelo. Vuelva verificar las condiciones de regresión. ¿La transformación mejoró las condiciones y desempeño del modelo desarrollado en 3d)?
- h) Haga un análisis de *outliers* del modelo 3g). ¿Existen *outliers*? Si existen, elimine el punto más extremo y vuelva a recalcular el modelo repitiendo el proceso indicado en 3g). ¿Mejóro la eliminación de ell(los) *outlier(s)* las condiciones y desempeño del nuevo modelo? Comente brevemente.

III. Material asociado

Para el desarrollo de la tarea se provee:

- Enunciado de la tarea.
- Datos de cada problema en formato `.xls` (`herpes.xls`, `presion.xls`, y `jet.xls`)

Todos estos archivos pueden ser descargados desde el buzón respectivo en CANVAS.

IV. Entrega

El plazo último de entrega es el **jueves 12 de junio a las 23:59** en el buzón de entrega correspondiente habilitado en CANVAS. Los documentos indicados más abajo deberán ser subidos como un sólo archivo comprimido en formato `.zip`:

- Archivo `.pdf` con el documento que contiene la resolución de la tarea con el nombre `Tarea_2_grupo_X.pdf`, donde X se refiere al número del grupo. El número de grupo se asignará en Canvas una vez que los grupos se conformen.
- Archivo(s) de Jupyter Notebook con código de Python con la resolución completa de la tarea. Si el grupo lo estima conveniente, se pueden agregar múltiples *notebooks* para mantener el orden y facilitar la revisión. Los archivos asociados deben ser rotulados usando el siguiente formato: `Tarea_2_grupo_X_script_Y.pdf`, donde X corresponde al número del grupo e Y corresponde al número correlativo que indica el número del *notebook*. Es importante destacar que los últimos archivos serán revisados en conjunto con el reporte de la tarea por lo que se recomienda que éstos estén debidamente comentados y ordenados.

V. Integridad Académica

Esta evaluación se adscribe al Código de Honor establecido por la Escuela de Ingeniería el que es vinculante. Todo trabajo evaluado en este curso debe ser propio. En caso de que exista colaboración permitida con otros estudiantes, el trabajo deberá referenciar y atribuir correctamente dicha contribución a quien corresponda. Como estudiante es su deber conocer la versión en línea del Código de Honor (<https://integridadacademica.uc.cl>). Los trabajos serán sometidos a revisión por plagio utilizando la herramienta Turnitin. Aquellos/as estudiantes que sean sorprendidos en conductas reñidas con la integridad académicas serán penalizados con nota mínima en la tarea (1.0), y dependiendo de la gravedad, los antecedentes serán enviados a las Unidades respectivas para sanciones más fuertes.